Université Paris Nanterre
Université Sorbonne nouvelle
Institut national des langues
et civilisations orientales

pluriTAL

Master Traitement Automatique des Langues http://plurital.org

Programmation et projet encadré - L7TI005

Web: HTML, HTTP, récupérer des pages

Crédits supports : Serge Fleury

Yoann Dupont, Serge Fleury prenom.nom@sorbonne-nouvelle.fr
Pierre Magistry pierre.magistry@inalco.fr

2022-2023

Université Sorbonne-Nouvelle
INALCO
Université Paris-Nanterre

Les enjeux de cette portion de cours :

- comprendre ce qu'est une page web
- comment on la récupère et on gère les erreurs
- avec quels outils, quels protocoles
- démarrer les aspirations d'URL

HTML

HTML, c'est quoi

HTML (**H**yper**T**ext **M**arkup **Language**) est un langage de balisage pour représenter des pages web. Format reconnu par tous les navigateurs.

HTML, c'est quoi

HTML (**H**yper**T**ext **M**arkup **Language**) est un langage de balisage pour représenter des pages web. Format reconnu par tous les navigateurs.

Permet de structurer l'information d'un page pour la rendre lisible :

- Dérivé du SGML (**S**tandard **G**eneralized **M**arkup **L**anguage) et "frère" du XML
- Permet de marquer des zones dans du contenu textuel
- Ces zones fournissent structure et enrichissements

Du balisage, à quoi ça ressemble ? I

HTML définit des balises qui marquent explicitement le début et la fin d'une zone. On peut inclure des balises dans d'autres, mais pas de chevauchement : HTML se rapproche donc des constituants syntaxiques :

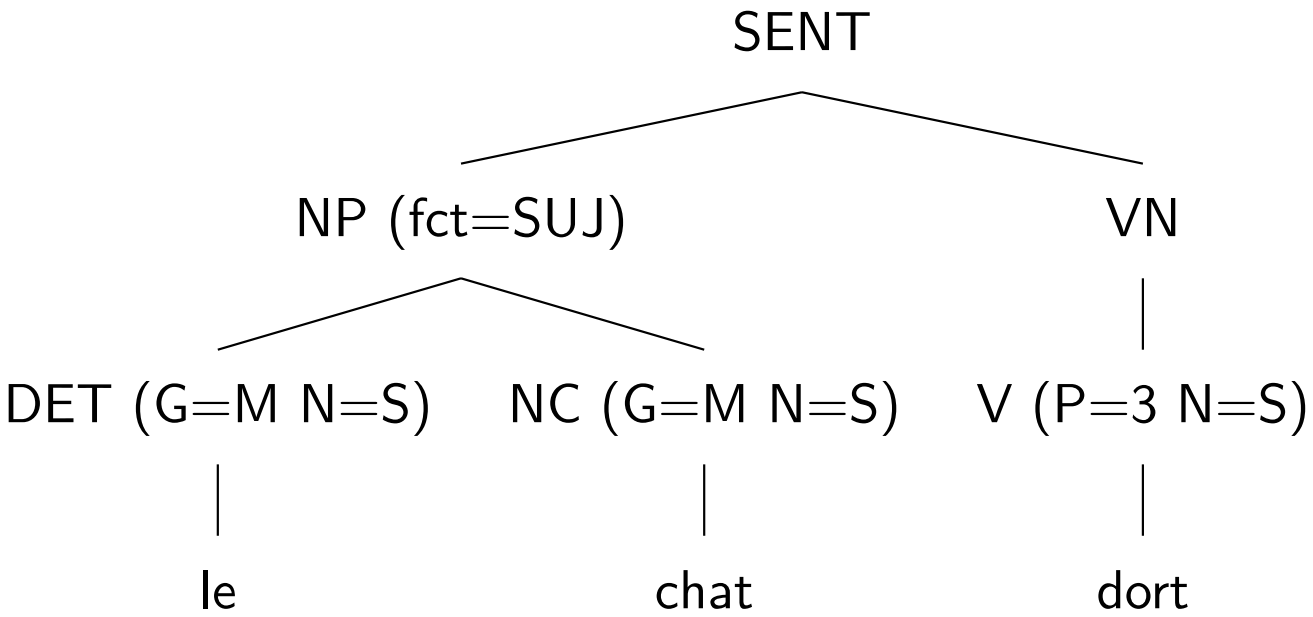

Du balisage, à quoi ça ressemble ? II

Pour moins d'ambiguïté, les balises sont marquées explicitement. il y en a 3 types :

- Ouvrantes : <balise> → le début d'une zone
- Fermantes : </balise> → la fin d'une zone
- Ouvrantes et fermantes à la fois : <balise/> → "ancre"

Du balisage, à quoi ça ressemble ? II

Pour moins d'ambiguïté, les balises sont marquées explicitement. il y en a 3 types :

- Ouvrantes : <balise> → le début d'une zone
- Fermantes : </balise> → la fin d'une zone
- Ouvrantes et fermantes à la fois : <balise/> → "ancre"

Les attributs d'une balise (donc du nœud) sont des couples clé/valeur renseignés sur la balise ouvrante :

- <NP fct="SUJ">
- <DET G="M" N="S">

Du balisage, à quoi ça ressemble ? III

Si on reprend l'exemple mais en XML :

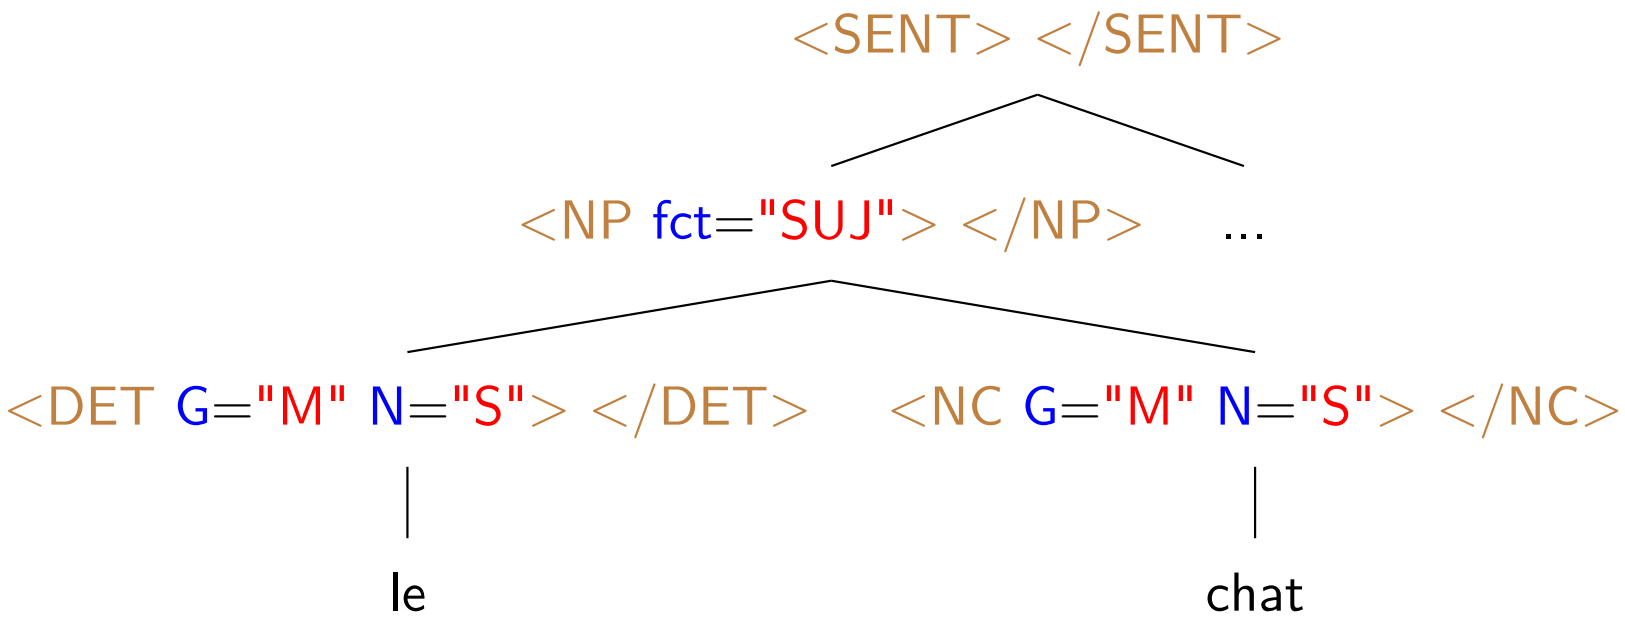

Du balisage, à quoi ça ressemble ? IV

Le fichier tel qu'il sera écrit au format texte :

```
<SENT>
    <NP fct="SUJ">
        <DET G="M" N="S">Le</DET>
        <NC G="M" N="S">chat</NC>
    </NP>
    <VN>
        <V P="3" N="S">dort</V>
    </VN>
</SENT>
```

HTML : les spécificités

HTML reprend la construction globale du balisage, mais a sa propre syntaxe :

```
<html>
    <head>...</head>
    <body>...</body>
</html>
```

HTML : les spécificités

HTML reprend la construction globale du balisage, mais a sa propre syntaxe :

```
<html>
    <head>...</head>
    <body>...</body>
</html>
```

Où :

- head : l'entête du fichier (avec les métadonnées)
- body : le corps du fichier (avec le contenu textuel et la structure)

Bonne ressource pour approfondir HTML : https://www.w3schools.com/html/default.asp

HTML : l'entête

L'entête `head`[1] contient beaucoup d'informations intéressantes. On reviendra plus en détail plus tard sur certaines.

Une métadonnée particulière nous sera intéressante ici : l'encodage (charset)[2].

[1] Documentation entête HTML : https://www.w3schools.com/html/html_head.asp
[2] Documentation charset HTML : https://www.w3schools.com/html/html_charset.asp

HTML : l'entête

L'entête `head`[1] contient beaucoup d'informations intéressantes. On reviendra plus en détail plus tard sur certaines.

Une métadonnée particulière nous sera intéressante ici : l'encodage (charset)[2].

```
<html>
    <head>
        [...]
        <meta  charset="UTF-8" />
        [...]
    </head>
    <body>...</body>
</html>
```

[1] Documentation entête HTML : https://www.w3schools.com/html/html_head.asp
[2] Documentation charset HTML : https://www.w3schools.com/html/html_charset.asp

HTML : Créer un tableau

Pour créer un tableau en HTML, nous avons besoin de 4 balises :

- `table` : la balise racine du tableau
- `tr` : ***t****able* ***r****ow*, une ligne (se place dans table)
- `th` : ***t****able* ***h****eader*, une cellule d'entête (seulement la première ligne)
- `td` : ***t****able* ***d****ata*, une cellule classique (toutes les lignes pas entête)

---

https://www.w3schools.com/html//html_tables.asp

HTML : Créer un tableau

Pour créer un tableau en HTML, nous avons besoin de 4 balises :

- `table` : la balise racine du tableau
- `tr` : ***t**able **r**ow*, une ligne (se place dans table)
- `th` : ***t**able **h**eader*, une cellule d'entête (seulement la première ligne)
- `td` : ***t**able **d**ata*, une cellule classique (toutes les lignes pas entête)

```
<table>
   <tr><th>livre</th><th>taille</th></tr>
   <tr>
      <td>Du côté de chez Swann</td><td>1.0Mo</td>
   </tr>
   <tr>
      <td>L'Assommoir</td><td>990 ko</td>
   </tr>
</table>
```

https://www.w3schools.com/html//html_tables.asp

Lynx

Que fait un navigateur ?

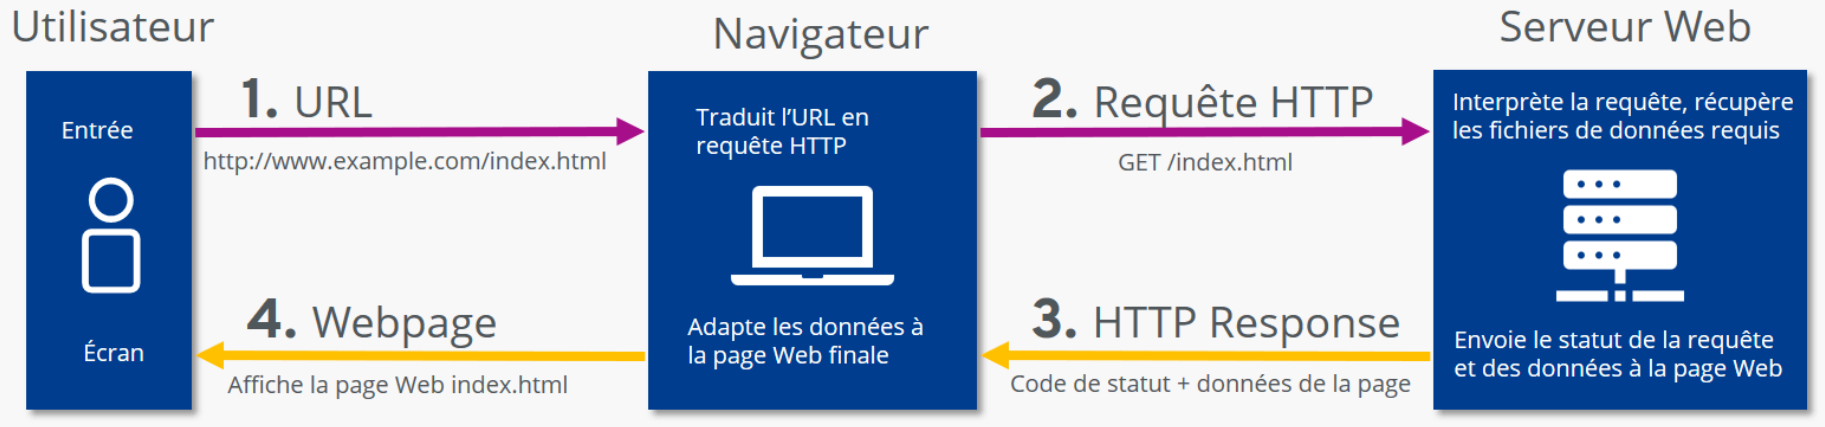

Figure 1: Schématisation de HTTP (source : www.ionos.fr)

Que fait un navigateur ?

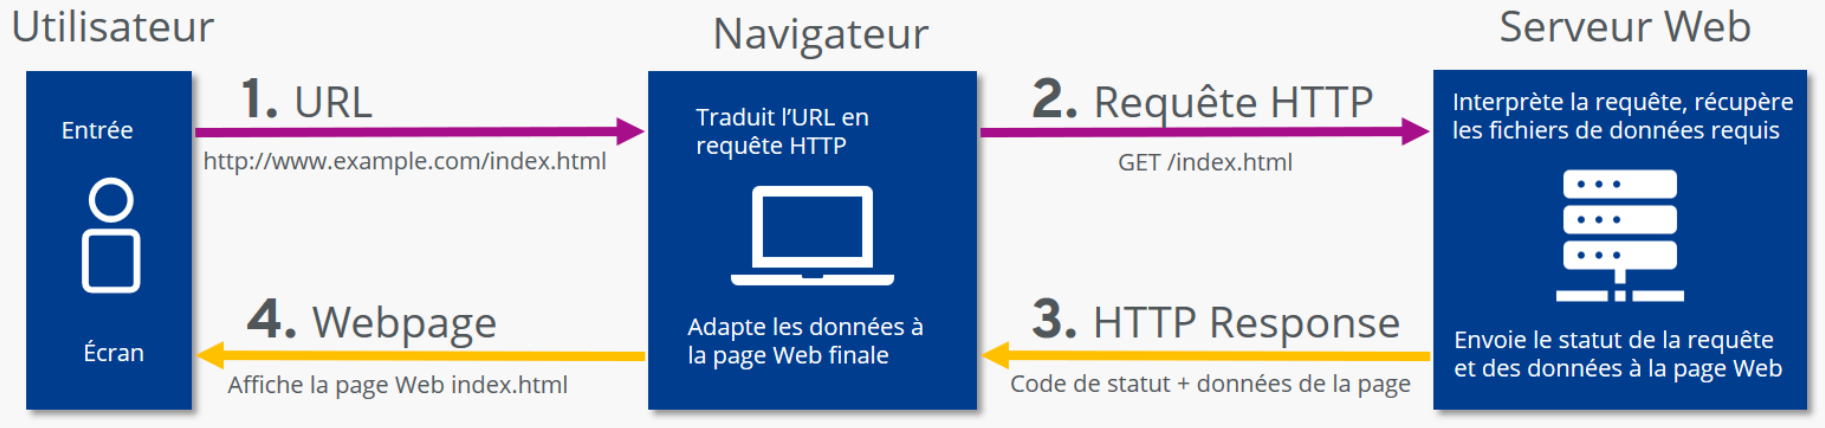

Figure 1: Schématisation de HTTP (source : `www.ionos.fr`)

L'étape 4 est l'interprétation de la page par votre navigateur.

Présentation

Lynx est un navigateur web en terminal. Cela lui donne des propriétés particulièrement intéressantes.

[3] Installer homebrew sur Mac :
https://osxdaily.com/2018/03/07/how-install-homebrew-mac-os/

[4] Installer Lynx avec homebrew :
https://osxdaily.com/2011/07/26/get-lynx-for-mac-os-x-10-7-lion/

Présentation

Lynx est un navigateur web en terminal. Cela lui donne des propriétés particulièrement intéressantes.

Installer sur Linux (terminal) :

```
sudo apt install lynx
```

Installer sur Mac OS X avec `homebrew`[3,4] (terminal) :

```
brew install lynx
```

[3] Installer homebrew sur Mac :
https://osxdaily.com/2018/03/07/how-install-homebrew-mac-os/

[4] Installer Lynx avec homebrew :
https://osxdaily.com/2011/07/26/get-lynx-for-mac-os-x-10-7-lion/

Démonstration

Récupérer le contenu d'une page avec Lynx

Lynx, comme on l'a vu, permet d'afficher une page web avec uniquement du texte et des liens.

Une option permet de récupérer le contenu textuel (sans liens) d'une page pour l'afficher à l'écran. Laquelle et comment la chercher ?

wget, cURL

Pourquoi

`wget` et `cURL` (*client URL Request Library*) sont deux commandes qui vont pouvoir nous permettre de récupérer des pages web sans passer par un navigateur. Les deux commandes ont des différences qui les rendent intéressantes, même si on privilégiera `cURL`.

Pourquoi

`wget` et `cURL` (*client URL Request Library*) sont deux commandes qui vont pouvoir nous permettre de récupérer des pages web sans passer par un navigateur. Les deux commandes ont des différences qui les rendent intéressantes, même si on privilégiera `cURL`.

Dans notre cas, la différence principale entre les deux commandes et que `wget` écrit dans un fichier et `cURL` écrit dans le terminal.

Installer cURL et wget

Sous Linux via le terminal (wget déjà installé) :

```
sudo apt install curl
```

Sous Mac OS X avec homebrew :

```
brew install wget
brew install curl
```

La commande cURL

Lancer la commande cURL :

```
curl <URL>
```

Où <URL> est une URL vers une page sur le web.

La commande cURL

Lancer la commande cURL :

```
curl <URL>
```

Où <URL> est une URL vers une page sur le web.

Quelques options utiles :

- -i : va donner des informations sur l'interaction avec le serveur
- -L : suit les redirections
- -O <fichier> : indique un <fichier> de sortie
- d'autres à voir par vous-même : -I (i), -w, -s

Quelques tests intéressants avec cURL I

```
curl www.perdu.com
curl www.google.com
curl www.youtube.com
curl www.github.com
```

Quelques tests intéressants avec cURL II

Regardons déjà les cas où ça va (ou ça fait semblant d'aller ?) :

```
curl -i www.perdu.com
curl -i www.google.com
```

Quelques tests intéressants avec cURL II

Regardons déjà les cas où ça va (ou ça fait semblant d'aller ?) :

```
curl -i www.perdu.com
curl -i www.google.com
```

Et les cas où ça ne va pas :

```
curl -iL www.youtube.com
curl -i www.github.com
```

Quelques tests intéressants avec cURL II

Regardons déjà les cas où ça va (ou ça fait semblant d'aller ?) :

```
curl -i www.perdu.com
curl -i www.google.com
```

Et les cas où ça ne va pas :

```
curl -iL www.youtube.com
curl -i www.github.com
```

Ce qu'on voit avec ces commandes, ce sont des informations sur la réponse du serveur. Deux lignes nous intéressent tout particulièrement :

- La première de chaque bloc d'entête : `HTTP/1.1 XZY <message>`
- Celle souvent juste après : `content-type: <informations>`

Quelques tests intéressants avec cURL II

Regardons déjà les cas où ça va (ou ça fait semblant d'aller ?) :

```
curl -i www.perdu.com
curl -i www.google.com
```

Et les cas où ça ne va pas :

```
curl -iL www.youtube.com
curl -i www.github.com
```

Ce qu'on voit avec ces commandes, ce sont des informations sur la réponse du serveur. Deux lignes nous intéressent tout particulièrement :

- La première de chaque bloc d'entête : `HTTP/1.1 XZY <message>`
- Celle souvent juste après : `content-type: <informations>`

Il s'agit d'un résumé de la communication entre le client (nous) et le serveur (le site hébergé quelque part sur le net). Ces informations sont issues du protocole HTTP.

HTTP

Présentation

***H**ypertext **T**ransfer **P**rotocol*. Protocole de communication entre un client et un serveur pour transmettre pages, média, etc.

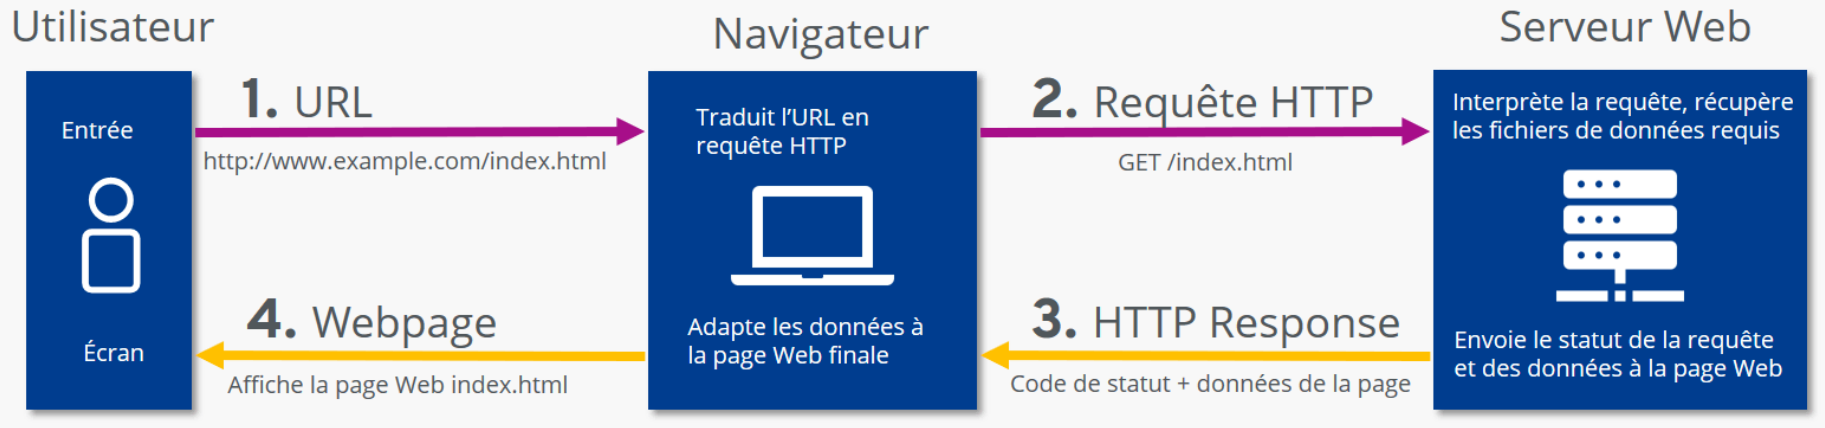

Figure 2: Schématisation de HTTP (source : www.ionos.fr)

Présentation

***H**ypertext **T**ransfer **P**rotocol*. Protocole de communication entre un client et un serveur pour transmettre pages, média, etc.

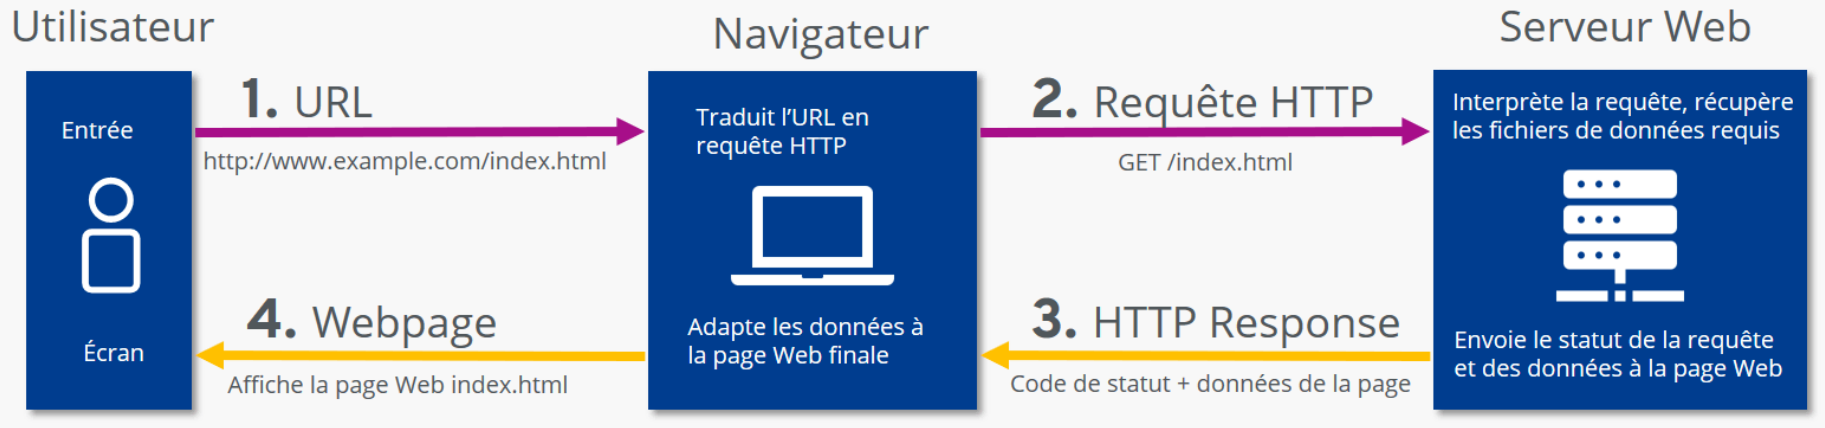

Figure 2: Schématisation de HTTP (source : `www.ionos.fr`)

Lorsqu'on utilise des outils comme `cURL`, le code de statut permet de connaître rapidement le résultat d'une requête.

Nomenclature des codes HTTP

Permettent d'avoir le statut de la réponse :

- 1xx : information
- 200 : réussite
- 3xx : redirections
- 4xx : erreurs du client
- 5xx : erreurs du serveur

On utilisera ces codes pour (in)valider les requêtes dans les fichiers d'URL.

Source : https://fr.wikipedia.org/wiki/Liste_des_codes_HTTP

Utiliser le tout pour commencer la récolte

L'allure générale du travail de récolte

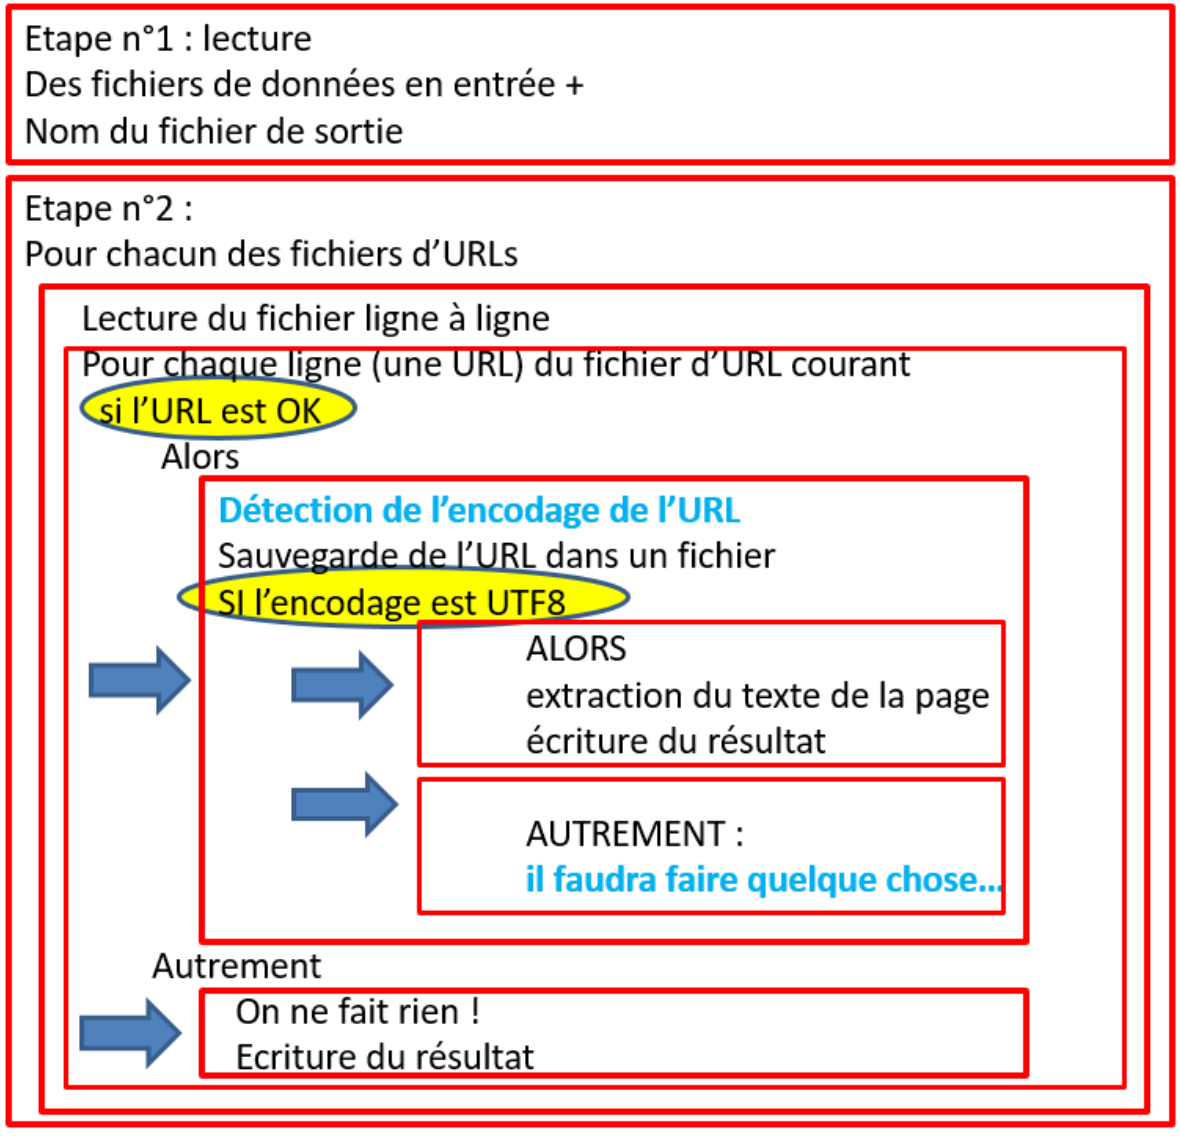

Figure 3: crédits : Serge Fleury

Construction du script

Votre script devra faire plusieurs choses :

- récupérer les URL d'un fichier texte
- écrire un tableau dans un fichier HTML

On a donc deux arguments : le fichier d'URL et le fichier de sortie où on écrire le tableau.

Lire les lignes d'un fichier en bash

pour lire les lignes du fichier "urls.txt", on peut utiliser le code suivant :

```
while read -r line;
do
    echo $line;
done < "urls.txt";
```

Questions :

1. Pourquoi ne pas utiliser cat ?
2. Comment transformer "urls.txt" en paramètre ?
3. Comment écrire un tableau d'URL en HTML dans le fichier de sortie ?
   3.1 Le HTML devra être encodé en `UTF-8` et le mentionner dans l'entête.
4. Comment y rajouter le numéro de ligne pour chaque URL ?

Transformer le script pour lire un dossier

À partir de votre code basé sur :

```
while read -r line;
do
    echo $line;
done < "urls.txt";
```

Toujours en gardant deux paramètres pour votre script :

1. Comment lire non pas un fichier, mais un dossier d'URL ?
2. Comment séparer les résultats dans un dossier de sortie par langue ?